

第一讲：导论与动态建模

异质性主体宏观经济学的计算方法

孙杰

2026 年 5 月 11 日

多伦多大学

模型结构

本系列幻灯片：使用 Julia 求解带或不带总量冲击的异质性主体（heterogeneous-agent, HA）一般均衡（general equilibrium, GE）模型。

我们涵盖具有以下形式的离散时间 GE 模型：

1. 由若干**阶段**（Stages）构成的前瞻性家庭模块
2. 一组描述经济其余部分（厂商、政府等）的方程，通常表示为函数的**有向无环图**（directed acyclic graph, DAG）
3. 一组**外循环**（outer loops），用于求解均衡、稳态、校准、转移路径或全局解等

课程结构

- 第 1–4 讲：阶段 (Stages)。
- 第 5–8 讲：外循环 (outer loops)。
 - 最终引出“神经价值函数迭代” (neural Value Function Iteration, nVFI) 全局求解算法

动机

异质性主体：动机一

- 经验上的平均边际消费倾向 (marginal propensity to consume, MPC) 较高，但平均储蓄**同样**较高。
- 典型的代表性主体模型难以解释这一点。
- 然而，如果穷人具有高 MPC 与低储蓄，富人具有低 MPC 与高储蓄，那么**异质性主体**模型就能解释。

异质性主体：动机二

- 政策（例如利率政策）的变化会以**不同方式**影响不同的人。
- 一项政策的**总量**效应取决于它针对的是谁。
- 我们关心政策的分布效应与总量后果。

家庭问题：两期模型

微观基础：单个家庭

- 宏观经济学研究的是个体行为如何塑造总量结果。
- 要理解总量结果的来源，必须研究个体行为的来源。

两期模型

家庭在第 0 期持有**财富** b_0 。第 1 期获得收入 z_1 。

$$\begin{aligned} \max_{c_0, c_1 \geq 0} \quad & u(c_0) + \beta u(c_1) \\ \text{s.t.} \quad & b_0 + \frac{z_1}{R} \geq c_0 + \frac{c_1}{R}. \end{aligned}$$

- 如果今天储蓄 \$1，明天可以消费 \$ R ，但效用按 β 折现。
- 拉格朗日函数： $\mathcal{L} = u(c_0) + \beta u(c_1) - \lambda \left(c_0 + \frac{c_1}{R} - b_0 - \frac{z_1}{R} \right)$ 。

欧拉方程

拉格朗日 FOC:

$$\begin{aligned}u'(c_0) &= \lambda, \\ \beta u'(c_1) &= \frac{\lambda}{R}.\end{aligned}$$

整理得,

$$\boxed{\frac{u'(c_0)}{u'(c_1)} = \beta R.}$$

在最优点, 家庭对于“今天多消费一单位”与“今天储蓄一单位、明天获得 R 单位”是**无差异**的。

例：对数效用下的解析解

设 $u(c) = \log c$ 。则 $c_1 = \beta R c_0$ ，且

$$c_0^* = \frac{b_0 + \frac{z_1}{R}}{1 + \beta}, \quad c_1^* = \frac{\beta R b_0 + \frac{z_1}{R}}{1 + \beta}.$$

取 $\beta = 0.96$ 、 $R = 1.04$ 、 $b_0 = 10$ 、 $z_1 = 2$ ：

$$c_0^* \approx 6.08, \quad c_1^* \approx 6.07.$$

存在**消费平滑** (consumption smoothing)。收入序列 $(10, 2)$ 起伏较大，消费序列 $(6.08, 6.07)$ 则平稳得多。

策略函数

策略函数 (policy function) 以**初始财富** b_0 表示第 0 期的最优消费：

$$c_0^*(b_0) = \frac{b_0 + z_1/R}{1 + \beta}.$$

这样我们就建立了一个关于家庭行为以及**家庭行为**如何产生的模型。

CRRA 偏好

常用的假设是常相对风险厌恶 (constant relative risk aversion, CRRA) 效用:

$$u(c) = \begin{cases} \frac{c^{1-\gamma}-1}{1-\gamma}, & \gamma > 0, \gamma \neq 1, \\ \log c, & \gamma = 1. \end{cases}$$

效用关于 c 递增:

$$\frac{\partial u(c)}{\partial c} = c^{-\gamma} > 0.$$

效用为凹函数: 边际效用关于 c 递减:

$$\frac{\partial^2 u(c)}{\partial c^2} = -\gamma c^{-\gamma-1} < 0.$$

家庭问题： T 期模型

T 期模型

终生效用为

$$\max_{c_0, \dots, c_{T-1}} \sum_{t=0}^{T-1} \beta^t u(c_t), \quad b_{t+1} = R(b_t - c_t) + z_{t+1}.$$

求解拉格朗日函数会得到 $T - 1$ 个欧拉方程：

$$u'(c_t) = \beta R u'(c_{t+1}).$$

如果未来收入完全可预见，问题仍然容易求解。

那如果收入是随机的呢？

随机收入

- 假设 $\{z_t\}$ 服从转移矩阵为 Π 的马尔可夫链 (Markov chain)。
- 给定今天的 z_t ，我们知道 z_{t+1} 的条件分布，但不知道实现值。
- 在每一期 t ，家庭在不知道 z_{t+1} 的情况下选择 c_t 。

随机欧拉方程

取 $T = 2$ ，可代入约束：

$$c_1 = R(b_0 - c_0) + z_1.$$

问题变为

$$\max_{c_0} u(c_0) + \beta \mathbb{E} [u(R(b_0 - c_0) + z_1)],$$

对 c_0 的一阶条件为

$$u'(c_0) = \beta R \mathbb{E} [u'(c_1)].$$

欧拉方程现在包含了对不确定的 c_1 的期望。

无限期问题 ($T = \infty$)

令人意外的是，当 $T \rightarrow \infty$ 时问题反而稍微容易些：

$$\begin{aligned} \max \mathbb{E}_0 \sum_{t=0}^{\infty} \beta^t u(c_t) \\ \text{s.t. } b_{t+1} = R(b_t - c_t) + z_{t+1}. \end{aligned}$$

但我们究竟在对什么取 $\max$ ？严格地说，需要找到一整个**策略函数**序列：

$$c_t = c_t(z_0, \dots, z_t) \quad \forall t,$$

这看上去几乎不可行。所幸我们可以通过重新表述来简化问题。

(注：此处略去横截条件 (transversality condition) 的问题。)

递归形式

Richard Bellman 的第一个观察

在每一时刻 t ，家庭只做一个选择，然后等待：

$$\begin{aligned} \max_{c_t} &= u(c_t) + \beta \mathbb{E}_t \left[\max \mathbb{E}_{t+1} \sum_{s=t+1}^{\infty} \beta^s u(c_s) \right] \\ \text{s.t.} \quad &b_{s+1} = R(b_s - c_s) + z_{s+1} \quad \forall s \geq t. \end{aligned}$$

关键在于， t 时的问题与 $t+1$ 时的问题**几乎**完全相同。

仅有的差异可能来自 b_t 与 z_t 。它们就是**状态变量** (state variables)。

状态变量

- 非正式地说，**状态变量**是那些让不同时期（以及不同决策）产生实质性差别的变量。
- 在这里，状态变量是财富 b_t 与收入 z_t 。给定它们，家庭的未来条件期望效用与最优决策就被唯一决定。

Bellman 的第二与第三个观察

Bellman 还意识到另外两点：

2. 可以将第一个洞见表述为关于**值函数** (value function) V 的方程。
3. 一旦知道这个**值函数**，就能计算**策略函数**并（数值地）求解整个模型。

用计算机科学的话说，这是一种**缓存** (caching)。

值函数与贝尔曼方程

定义值函数 $V(b, z)$ 为状态为 (b, z) 时未来效用的**净现值**：

$$V(b, z) = \max_{c \in [0, b]} \mathbb{E}_0 \sum_{s=0}^{\infty} \beta^s u(c_s)$$

s.t. $b_{s+1} = R(b_s - c_s) + z_{s+1} \quad \forall s.$

（前提是未来所有选择也都是最优的。）

那么 V 满足**贝尔曼方程**（Bellman equation）：

$$V(b, z) = \max_{c \in [0, b]} u(c) + \beta \mathbb{E}[V(b', z') \mid z]$$

s.t. $b' = R(b - c) + z'$

值函数就是一切

一旦知道 V ，就可以计算**策略函数**并求解整个（家庭）模型：

$$c^*(b, z) = \arg \max_{c \in [0, b]} u(c) + \beta \mathbb{E}[V(R(b - c) + z, z') \mid z].$$

如何找到 V ?

- 但仍然存在一个问题：我们需要找到的不是一个数，而是一整个**函数** V 。
- 可以通过“值函数迭代”（Value Function Iteration, VFI）做到这一点。
- 为理解 VFI：先设想我们猜测了一个值函数，并且猜**错**了。

贝尔曼算子作用于任意 v

假设我们猜测了一个**函数** v_0 。即便 v 可能是**错的**，它仍然会预测某个策略：

$$c^*(b, z; v) = \arg \max_{c \in [0, b]} u(c) + \beta \mathbb{E}[v(R(b - c) + z', z') \mid z].$$

若用 v 进行**前瞻**，可以得到**另一个函数** $\mathcal{T}v$ ：

$$(\mathcal{T}v)(b, z) := \max_{c \in [0, b]} u(c) + \beta \mathbb{E}[v(R(b - c) + z', z') \mid z].$$

v 可以被理解为对处在状态 (b, z) 的价值的**信念**。

$\mathcal{T}v$ 则表示通过向前看一期之后得到的**更新后的信念**。

贝尔曼算子

- 可以把 $\mathcal{T}$ 看作把**函数**映射到**函数**的**算子**: $v \mapsto \mathcal{T}v$ 。
- 这就是**贝尔曼算子** (Bellman operator)。
- 贝尔曼方程可重写为

$$V = \mathcal{T}V.$$

- 求解家庭问题相当于寻找 $\mathcal{T}$ 的**不动点** (fixed point)。

存在性与唯一性

我们不打算证明，但值得指出：Banach 不动点定理（Banach's fixed point theorem）保证，在温和条件下， $\mathcal{T}$ 存在**唯一**的不动点 V 。

关键在于 $\mathcal{T}$ 是一个压缩映射（contraction）：

$$\|\mathcal{T}v_1 - \mathcal{T}v_2\|_\infty \leq \beta \|v_1 - v_2\|_\infty.$$

Banach 定理由此给出：

1. 存在唯一的不动点 V 。
2. 从任意初始 v_0 出发，迭代 $v_{k+1} = \mathcal{T}v_k$ 以速率 β 收敛到 V 。


再看一次：贝尔曼方程

$$V(\text{状态}) = \max_{\text{动作}} \text{payoff}(\text{状态}, \text{动作}) + \beta \mathbb{E}[V(\text{下一状态}) \mid \text{状态}, \text{动作}]$$

本课程余下的内容基本上都是这一公式的变种。

后续讲座

后续讲座



配套笔记本

每讲都配有一个 Jupyter 笔记本。

1. Julia 1.10+
<https://julialang.org/downloads/>
2. VS Code 加 Julia 扩展。
3. `using Pkg; Pkg.add("IJulia")`。
4. Jupyter (Anaconda 或 `pip install jupyter`)。