

第一讲：引论与动态建模

异质性主体宏观经济学的计算方法

孙振越 (Jeffrey Sun)

2026 年 5 月 11 日

多伦多大学

模型结构

本课程幻灯片：在 Julia 中求解含或不含总量冲击的异质性主体（HA）一般均衡（GE）模型。

我们讨论具有如下形式的离散时间一般均衡模型：

1. 由若干**阶段**（Stages）构成的前瞻性家庭模块
2. 一组描述经济其余部分（如厂商、政府等）的方程，通常表示为函数的**有向无环图**（DAG）。
3. 一组**外层循环**，用于求解诸如均衡、稳态、校准、转移或全局解

课程结构

- 第 1–4 讲：阶段。
- 第 5–8 讲：外层循环。
 - 最终引出“神经值函数迭代”（nVFI）全局求解算法

动机

异质性主体：动机一

- 经验上平均边际消费倾向（MPC）较高，而平均储蓄**也**较高
- 典型的代表性主体模型难以轻易解释这一点。
- 然而，若贫困家庭具有高 MPC、低储蓄，而富裕家庭具有低 MPC、高储蓄，则**异质性主体**模型便可加以解释。

异质性主体：动机二

- 政策（例如利率）的变化会对不同的人产生**不同**的影响
- 一项政策的**总量**效应取决于它针对的对象，因而各不相同。
- 我们关心政策在分布层面和总量层面的后果。

家庭问题：两期

微观基础：单个家庭

- 宏观经济学研究的是个体行为如何塑造总量结果。
- 要理解宏观结果的根源，就需要研究个体行为的来源。

两期模型

家庭在第 0 期以**财富** b_0 开始。在第 1 期，家庭获得收入 z_1 。

$$\max_{c_0, c_1 \geq 0} u(c_0) + \beta u(c_1)$$

$$\text{s.t.} \quad b_0 + \frac{z_1}{R} \geq c_0 + \frac{c_1}{R}.$$

- 若今天储蓄 \$1，明天便可花费 \$R，但效用被 β 折现。
- 拉格朗日函数： $\mathcal{L} = u(c_0) + \beta u(c_1) - \lambda \left(c_0 + \frac{c_1}{R} - b_0 - \frac{z_1}{R} \right)$ 。

欧拉方程

拉格朗日一阶条件：

$$\begin{aligned}u'(c_0) &= \lambda, \\ \beta u'(c_1) &= \frac{\lambda}{R}.\end{aligned}$$

整理可得，

$$\boxed{\frac{u'(c_0)}{u'(c_1)} = \beta R.}$$

在最好处，对于今天多消费一单位、还是把它储蓄以换取明天的 R 单位，家庭是**无差异**的。

示例：对数效用下的解析解

设 $u(c) = \log c$ 。则 $c_1 = \beta R c_0$ ，且

$$c_0^* = \frac{b_0 + \frac{z_1}{R}}{1 + \beta}, \quad c_1^* = \frac{\beta R b_0 + \frac{z_1}{R}}{1 + \beta}.$$

当 $\beta = 0.96$ 、 $R = 1.04$ 、 $b_0 = 10$ 、 $z_1 = 2$ 时：

$$c_0^* \approx 6.08, \quad c_1^* \approx 6.07.$$

这里存在**消费平滑**。收入是起伏不平的 $(10, 2)$ ，而消费则更为平滑，为 $(6.08, 6.07)$ 。

策略函数

策略函数将最优的第 0 期消费表示为**初始财富** b_0 的函数，

$$c_0^*(b_0) = \frac{b_0 + z_1/R}{1 + \beta}.$$

这样，我们便得到了一个关于家庭行为、以及**家庭行为**如何产生的模型。

CRRA 偏好

一个标准的假设是常相对风险厌恶（CRRA）效用，

$$u(c) = \begin{cases} \frac{c^{1-\gamma}-1}{1-\gamma}, & \gamma > 0, \gamma \neq 1, \\ \log c, & \gamma = 1. \end{cases}$$

效用关于 c 递增，

$$\frac{\partial u(c)}{\partial c} = c^{-\gamma} > 0.$$

效用是凹的：边际效用关于 c 递减，

$$\frac{\partial^2 u(c)}{\partial c^2} = -\gamma c^{-\gamma-1} < 0.$$

家庭问题：T 期

T 期模型

终身效用由下式给出，

$$\max_{c_0, \dots, c_{T-1}} \sum_{t=0}^{T-1} \beta^t u(c_t), \quad b_{t+1} = R(b_t - c_t) + z_{t+1}.$$

求解拉格朗日函数可得 $T - 1$ 个欧拉方程，

$$u'(c_t) = \beta R u'(c_{t+1}).$$

如果未来收入被完全预见，仍然可以相当容易地求解。

但如果收入是随机的呢？

随机收入

- 假设 $\{z_t\}$ 服从转移矩阵为 Π 的马尔可夫链
- 给定今天的 z_t ，我们知道 z_{t+1} 的条件分布，但不知道其实现值
- 在每一期 t ，家庭在不知道 z_{t+1} 的情况下选择 c_t

随机欧拉方程

当 $T = 2$ 时，我们可以代入，

$$c_1 = R(b_0 - c_0) + z_1.$$

于是问题就是，

$$\max_{c_0} u(c_0) + \beta \mathbb{E} [u(R(b_0 - c_0) + z_1)],$$

关于 c_0 的一阶条件为，

$$u'(c_0) = \beta R \mathbb{E} [u'(c_1)].$$

现在欧拉方程中包含了对不确定的 c_1 取期望。

无限期问题 ($T = \infty$)

说来或许令人意外，如果我们取 $T \rightarrow \infty$ ，问题实际上反而稍微简单一些：

$$\begin{aligned} \max \mathbb{E}_0 \sum_{t=0}^{\infty} \beta^t u(c_t) \\ \text{s.t. } b_{t+1} = R(b_t - c_t) + z_{t+1}. \end{aligned}$$

但我们是在对什么取 $\max$ 呢？严格来说，我们需要找到一整个序列的**策略函数**，

$$c_t = c_t(z_0, \dots, z_t) \quad \forall t,$$

但这看起来几乎是不可能的。所幸，我们可以通过重新表述问题来加以简化。
(注：此处略去横截性条件的问题。)

递归形式

Bellman 的第一个观察

在每一时刻 t ，家庭只做出一个选择，然后等待，

$$\begin{aligned} \max_{c_t} &= u(c_t) + \beta \mathbb{E}_t \left[\max \mathbb{E}_{t+1} \sum_{s=t+1}^{\infty} \beta^s u(c_s) \right] \\ \text{s.t. } & b_{s+1} = R(b_s - c_s) + z_{s+1} \quad \forall s \geq t. \end{aligned}$$

重要的是，时刻 t 的问题与时刻 $t+1$ 的问题看起来**几乎**完全相同。

唯一可能的差异在于 b_t 和 z_t 。这些就是**状态变量**。

状态变量

- 非正式地说，**状态变量**就是那些使各个时期（以及各项决策）彼此之间产生实质性差异的变量。
- 在这里，状态变量是财富 b_t 和收入 z_t 。给定这些变量，家庭未来的条件期望效用和最优决策便被唯一确定。

Bellman 的第二和第三个观察

Bellman 还意识到另外两件事：

2. 可以将第一个洞见表述为一个关于**值函数** V 的方程。
3. 如果你知道这个**值函数**，就可以计算出**策略函数**，并（在数值上）求解整个模型。

用计算机科学的术语来说，这是**缓存**的一个例子。

值函数与贝尔曼方程

将值函数 $V(b, z)$ 定义为给定状态 (b, z) 时未来效用的**净现值**。

$$V(b, z) = \max_{c \in [0, b]} \mathbb{E}_0 \sum_{s=0}^{\infty} \beta^s u(c_s)$$
$$\text{s.t. } b_{s+1} = R(b_s - c_s) + z_{s+1} \quad \forall s.$$

（前提是所有未来的选择也都将以最优方式做出。）

那么 V 满足**贝尔曼方程**

$$V(b, z) = \max_{c \in [0, b]} u(c) + \beta \mathbb{E}[V(b', z') \mid z]$$

$$\text{s.t. } b' = R(b - c) + z'$$

值函数就是你所需要的一切

如果我们知道 V ，就可以计算出**策略函数**，并求解整个（家庭）模型，

$$c^*(b, z) = \arg \max_{c \in [0, b]} u(c) + \beta \mathbb{E}[V(R(b - c) + z, z') \mid z].$$

我们如何找到 V ?

- 不过，我们仍然面临一个问题。我们要找的不只是一个数，而是要找到一整个**函数** V 。
- 我们可以通过“值函数迭代”（VFI）来做到这一点。
- 为了理解这一点：先设想我们猜测了一个值函数，而且猜**错了**。

作用于任意 v 的贝尔曼算子

假设我们猜测了一个**函数** v 。即使 v 可能是**错的**，它仍然会预测出某个策略，

$$c^*(b, z; v) = \arg \max_{c \in [0, b]} u(c) + \beta \mathbb{E}[v(R(b - c) + z', z') \mid z].$$

如果我们用 v 来**向前看**，便可得到一个**不同的函数** $\mathcal{T}v$ ，

$$(\mathcal{T}v)(b, z) := \max_{c \in [0, b]} u(c) + \beta \mathbb{E}[v(R(b - c) + z', z') \mid z].$$

v 在某种意义上代表了对处于各种状态 (b, z) 之价值的**信念**。

$\mathcal{T}v$ 则代表了你通过向前看一期来推理后得到的**更新后的信念**。

贝尔曼算子

- 把 $\mathcal{T}$ 看作一个把函数映射为函数的算子： $v \mapsto \mathcal{T}v$ 。
- 这就是贝尔曼算子。
- 贝尔曼方程可以改写为，

$$V = \mathcal{T}V.$$

- 我们可以通过寻找 $\mathcal{T}$ 的不动点来求解家庭问题。

存在性与唯一性

我们不会证明这一点，但值得指出的是，巴拿赫不动点定理意味着，在温和的条件下， $\mathcal{T}$ 存在**唯一**的不动点 V_0 。

其想法在于 $\mathcal{T}$ 是一个压缩映射：

$$\|\mathcal{T}v_1 - \mathcal{T}v_2\|_\infty \leq \beta \|v_1 - v_2\|_\infty.$$

巴拿赫定理意味着：

1. 存在唯一的不动点 V_0 。
2. 从任意初始 v_0 出发迭代 $v_{k+1} = \mathcal{T}v_k$ ，都将以 β 的速率收敛到 V_0 。


再看一遍：贝尔曼方程

$$V(\text{状态}) = \max_{\text{行动}} \text{收益}(\text{状态}, \text{行动}) + \beta \mathbb{E}[V(\text{下一状态}) \mid \text{状态}, \text{行动}]$$

本课程余下的内容基本上都是这个方程的各种变体。

后续讲次

后续讲次



Notebook

每一讲都配有一个对应的 Jupyter notebook。

1. Julia 1.10+
<https://julialang.org/downloads/>
2. VS Code 加 Julia 扩展。
3. `using Pkg; Pkg.add("IJulia")`。
4. Jupyter (Anaconda 或 `pip install jupyter`)。